

TIỂU LUẬN CUỐI KỲ – KHOA HỌC DỮ LIỆU

PHÂN CỤM BỘ DỮ LIỆU VIỆC LÀM VIỆT NAM

Nhóm 09

Võ Trần Anh Quân (102230131)

Phạm Hữu Tuân (102230139)

Trần Việt Toàn (102230137)

Đà Nẵng, 05/2026



Bài Toán & Dataset

Bài toán

Phân cụm 606.878 bài đăng tuyển dụng Việt Nam — unsupervised, không có ground truth.

Output:

- Số cụm + hiệu suất (silhouette, Davies-Bouldin, Calinski-Harabasz)
- Thuộc tính chung mỗi cụm
- Nhân tự gán ý nghĩa kinh tế

Dataset (TINIX Vietnam Job Descriptions)

 606.878 dòng × 14 cột (Parquet -293MB nén, -1.5GB giải nén)

 Năm đăng 2022–2026

 Chủ yếu tiếng Việt, một phần Anh

 Split 90/10 (train 546k / test 60k), random_state = 42

EDA: Tổng quan và Phân phối lương

Chất lượng dữ liệu tốt

- Missing rất nhỏ: cao nhất benefits 0.65%, requirements 0.62%
- Không có cột nào thiếu trên 1%
- Không trùng id, không leak giữa train/test



Lương – text dạng "10.000.000 - 15.000.000 VND"

Cần parse bằng 4 regex pattern:

Pattern	%	Ví dụ
vnd_range_dotted	88%	"10.000.000 - 15.000.000 VND"
vnd_range_month	6.5%	"10000000 - 15000000 VND MONTH"
vnd_single_dotted	<0.01%	"12.000.000 VND"
usd_range	<0.01%	"500 - 1000 USD" (×25.000)

Tỉ lệ parse: ~95%

Còn lại "thỏa thuận", "0 VND", "đang cập nhật" → giữ với flag salary_missing.




EDA: Phát Hiện JUNK DATA

🔍 Junk 1: Sentinel 999.000.000 VND

- 642 dòng có max range = "999.000.000 VND"
- Đi kèm các vị trí bình thường: Phục Vụ, Pha Chế, Lễ Tân
→ chắc chắn là giá trị mặc định
- Drop trong stage cleaning

🔍 Junk 2: Bucket years_exp = 9

- 228 dòng, 99.6% có job_position = "Chưa cập nhật"
- So với bucket khác chỉ -5-10% missing → bất thường
- Phát hiện bằng luật: $n_rows < 500$ AND $pos_missing_rate > 0.5$
- Set NaN trong stage cleaning



EDA: Trục cluster tiềm năng và Train/Test

Lương phân bố khác biệt rõ theo nhiều trục


Trục	Insight
Years exp	Junior 8tr → Senior 22tr, tuyển tính
Ngành (top 50 cover 99.97%)	IT/BDS/Tài chính cao; Phổ thông thấp
Tỉnh/thành	HCM + Hà Nội chiếm 60%+
Năm đăng	2025–2026 chiếm phần lớn, lạm phát nhẹ

→ 4 trục cluster có ý nghĩa = ngành × kinh nghiệm × địa lý × lương.

Train ↔ Test KHÔNG lệch

Phân phối các biến chính giữa 2 tập gần như đồng nhất → split 90/10 ngẫu nhiên với seed 42 không gây distribution shift → model học từ train có thể generalize sang test.

EDA: Trục cluster tiềm năng Train/Test



Train ↔ Test KHÔNG lệch

Phân phối các biến chính giữa 2 tập gần như đồng nhất → split 90/10 ngẫu nhiên với seed 42 không gây distribution shift → model học từ train có thể generalize sang test.

Cleaning: Tổng quan và chuẩn hóa lương

Mục tiêu:

Sử dụng các quy tắc ở bước EDA để tiến hành làm sạch 545.000 mẫu dữ liệu ở tập train và 61.000 mẫu dữ liệu ở tập test. Kết quả thu được là một bộ dữ liệu sạch, giữ lại đúng 17 cột chuẩn nhất để làm bước tiếp theo.

Salary: 1 cột text → 3 feature numeric + 1 flag

"10.000.000 - 15.000.000 VND"

salary_min = 10.0 (triệu VNĐ)

salary_max = 15.0

salary_mid = 12.5

salary_missing = False

Lí do lựa chọn 3 feature:

- salary_mid mạnh nhất cho phân cụm theo mức lương
- salary_max - salary_min (biên độ) cho ta biết thông tin gộp nhiều vị trí hoặc thông tin lương không rõ ràng
- Cả 2 thông tin được giữ → cluster có chiều phong phú hơn

Cleaning: Xử lý ngoại lệ và gán cờ salary_missing

Xử lý Outlier

DROP dòng có sentinel ... -999.000.000 VND



- 33 dòng trong train, 100% là junk
- Lý do: K-Means dùng Euclidean distance → 1 dòng 850M kéo lệch centroid mạnh

DROP dòng salary_mid > 100M không sentinel

- 609 dữ liệu outlier
- Lý do: phá vỡ phân phối của chuẩn hóa StandardScaler

Xử lý dữ liệu gán cờ salary_mising

- Đánh dấu salary_missing = True
- Lý do: có thể là tín hiệu cụm riêng – "tin tuyển dụng giấu lương" thường là cấp manager/specialist



Cleaning: Chuẩn hóa dữ liệu thành các danh mục

years_exp — Regex + Junk bucket detection

- "3 năm" → 3.0
- "Dưới 1 năm" → 0.5
- "Không" → NaN
- Parse rate -96%
- Junk bucket 9 năm (228 dòng) → set NaN bằng rule auto

province — Regex 2 lớp

Lớp 1: match 63 tỉnh/thành Việt Nam trực tiếp

Lớp 2 (fallback): tra district → province


- HCM: Quận 1-12, Tân Bình, Bình Thạnh, Thủ Đức, ...
- Hà Nội: Hoàn Kiếm, Ba Đình, Đống Đa, ...

→ Coverage 94%, không match → 'Other'


industries_list — Multi-label

- Tách dấu / (vd. "Sales / CSKH / Bán lẻ")
- Top 50 ngành phổ biến + 'Other' cho phần còn lại
- Cover 99.97% tổng tokens
- Lưu pipe-separated: "Sales|CSKH|Bán lẻ"


Biểu đồ nhận diện dữ liệu rác years_exp



Top 15 địa điểm tuyển dụng (sau chuẩn hóa)



Top 20 ngành nghề tuyển dụng (sau chuẩn hóa)



Làm sạch và chia nhỏ để xử lý

Vấn đề: train CSV 1.1 GB, RAM 16 GB

Load full vào pandas → ~3-5 GB → có thể OOM khi xử lý.

Giải pháp: Chunked-Read + Write Incremental

Đọc 50.000 dòng/batch → Apply transforms → Append vào output CSV

Lặp 11 lần cho 545k dòng → done

Memory peak: chỉ ~500 MB (1 chunk DataFrame)

Disk I/O nhanh, đảm bảo chạy được trên máy phổ thông

Kết quả retain cao

Tập	Raw	Clean	Retain
Train	546.190	545.480	99.87%
Test	60.688	60.606	99.86%

Schema clean: 17 cột (thêm 3 cột salary + flag missing).

Feature Engineering


Pipeline – TF-IDF + TruncatedSVD (lexical features)

Nhóm	Chiều
Numeric (salary $\times$ 4 + years_exp + year)	6
OneHot (province, edu, type, position)	-95
MultiLabel industries	51
TF-IDF 4 cột text (max_df=0.85 + VN stopwords)	-25.500
Tổng sparse	-25.700
TruncatedSVD $\rightarrow$ dense 150D (giữ 77.7% variance)	[final]


Pipeline 2 – Sentence-BERT (semantic embedding)

- Model: paraphrase-multilingual-mpnet-base-v2 (768D, đa ngôn ngữ)
- Encode 606k JD trên GPU RTX 4060 50 phút (200 docs/s)
- L2-normalize $\rightarrow$ KMeans tương đương cosine clustering
- $\rightarrow$ 2 approach song song để so sánh ở stage clustering.


Biểu đồ phân phối 6 đặc trưng numeric sau chuẩn hóa



Top 15 TOKEN TF-IDF của 4 feature



Biểu đồ đường cong cumulative variance



K-search (k=5)

4 metric cho $k \in [3, 25]$





Metric	Hướng	Best k
Inertia	↓ luôn (elbow)	-5-6
Silhouette	↑	5 (0.128)
Davies-Bouldin	↓	5 (2.21)
Calinski-Harabasz	↑	3 (4110)

Optuna 30 trials TPE

- Mở rộng search (k, init, whitening_strength)
- Optuna chọn k=21 (sil 0.096) – tệ hơn grid k=5
- Whitening tuned $\approx 0 \rightarrow$ không tác dụng $\rightarrow$ Grid wins = chốt k=5 cho cả 2 pipeline

K-search (k=5)

K-search MiniBatchKMeans — 4 metric trên 545k x 100 SVD-normalized



5 cụm Pipeline 1 + NHÃN Ý NGHĨA

Pipeline 1 (TF-IDF + KMeans, k=5)

Cụm	n (%)	Lương	KN	Nhãn
0	21.6%	9.8tr	1.4y	Nhân viên junior phổ thông – Không bằng cấp
1	28.6%	10.4tr	2.2y	Nhân viên đa ngành mid-junior – CD/TC
2	19.9%	23.0tr	3.4y	Sales/BD lương cao + hoa hồng
3	24.5%	12.0tr	3.6y	Kế toán/Kiểm toán & Kỹ thuật mid
4	5.4%	NaN	3.1y	Tin lương "thoả thuận" – Manager/IT

3 insight nổi bật

- 🌟 Cụm 2 (-23tr): KHÔNG phải senior – là Sales/BDS/Bảo hiểm với commission cao (KN chỉ 3.4 năm)
- 🌟 Cụm 4 (5.4%): cụm đặc thù – tin tuyển dụng giấu lương = cấp manager + IT specialist
- 🌟 Cụm 0+1 (50%): lực lượng junior chiếm nửa thị trường VN


Pipeline 2: 5 cụm SBERT

Cụm	Nhân
0	Service/CSKH & Giáo dục junior
1	Sales & Customer-facing mid
2	Marketing & Education ★
3	Kế toán/Tài chính specialists ★
4	Engineering & Industrial ★

So với Pipeline 1

- TF-IDF gộp Marketing với Sales (vì cùng dùng "khách hàng", "bán hàng")
- SBERT tách Marketing, Engineering, Industrial riêng – hiểu ngữ cảnh
- Ví dụ JD "Nhân Viên Editor (Marketing)": TF-IDF phân SAI vào Sales, SBERT phân ĐÚNG vào Marketing

Pipeline 2 SBERT: Phân ngành sạch hơn – Tách ngành rõ hơn so với Pipeline 1



So sánh, Kết luận và Hướng phát triển

Bảng so sánh metric

Metric	Pipeline 1 (TF-IDF)	Pipeline 2 (SBERT)
Silhouette ↑	+0.128	+0.068
Davies-Bouldin ↓	2.21	3.31
Calinski-Harabasz ↑	3249	1406

Finding chính

TF-IDF lexical thắng metric nhưng SBERT semantic thắng diễn giải

Trade-off: metric vs interpretability. Advanced (SBERT) không phải lúc nào cũng tốt hơn.

Limitation

HDBSCAN không khả thi trên CPU consumer (>2.5h treo) – cần GPU implementation (cuML).

Hướng phát triển (4 mục ngắn)

- HDBSCAN trên NVIDIA RAPIDS cuML (GPU)
- Fine-tune PhoBERT cho domain JD VN → kỳ vọng sil 0.2-0.3
- Information Extraction kỹ năng cứng (Python, Excel, CAD, ...)
- GMM k=14 sub-cluster analysis